

Лекция 1. МАТЕМАТИЧЕСКАЯ СТАТИСТИКА

1. ПРЕДМЕТ МАТЕМАТИЧЕСКОЙ СТАТИСТИКИ. ГЕНЕРАЛЬНАЯ И ВЫБОРОЧНАЯ СОВОКУПНОСТЬ.

МАТЕМАТИЧЕСКАЯ СТАТИСТИКА – раздел математики, в котором изучаются методы сбора, систематизации и обработки результатов наблюдений массовых случайных явлений для выявления существующих закономерностей.

Как правило, статистическому исследованию подвергается некоторая совокупность однородных объектов, обладающих общим признаком.

Вся подлежащая изучению совокупность объектов называется **генеральной совокупностью**. **Объемом генеральной совокупности** называется количество объектов в ней.

Часто сплошное обследование объектов генеральной совокупности на предмет интересующего исследователя признака нецелесообразно по экономическим, временным и прочим соображениям (например, исследование изготавливаемых электрических лампочек на предмет срока их службы). В таких случаях прибегают к выборочному методу: из генеральной совокупности случайным образом извлекается некоторое подмножество объектов, которое называют **выборочной совокупностью**. Количество объектов выборочной совокупности называют **объемом выборки**.

Выборочная совокупность, основные свойства и характеристики которой незначительно отличаются от аналогичных свойств генеральной совокупности, называется **репрезентативной**.

Для того, чтобы обеспечить репрезентативность выборки и минимизировать неизбежные ошибки, возникающие при выборочном методе исследования, необходимо правильно организовать процедуру отбора, обеспечив соблюдение принципа равной возможности выбора любого из объектов генеральной совокупности.

На практике используются два способа образования выборки:

- **Повторный отбор**, когда каждый отобранный объект обследуется, затем возвращается в генеральную совокупность, после чего производится отбор следующего объекта. При таком способе отбора один и тот же объект может быть отобран несколько раз.
- **Бесповторный отбор**, когда отобранный элемент не возвращается в генеральную совокупность.

Следует отметить, что если объем генеральной совокупности очень велик, или бесконечен, а объем выборки по сравнению с ним незначителен, то различия между результатами анализа, полученными повторным и бесповторным способами стираются.

2. ВАРИАЦИОННЫЕ РЯДЫ. ГРАФИЧЕСКОЕ ИЗОБРАЖЕНИЕ ВАРИАЦИОННЫХ РЯДОВ.

Предположим, что генеральная совокупность исследуется на предмет некоторого признака (обозначим его X), присущего всем объектам этой совокупности. Будем считать, что для каждого из объектов можно получить числовое значение этого признака. Если отобрана выборка объема n из генеральной совокупности и для каждого объекта получено значение признака X , то в итоге будет сформирован массив из n чисел $x_1, x_2, \dots, x_n$, где x_i – значение признака X для i -го объекта.

Значения x_i называются **вариантами**, а они же, расположенные в порядке возрастания (неубывания) называются **вариационным рядом**.

Если признак X является дискретной случайной величиной, то среди значений x_i могут присутствовать одинаковые значения. Число m_i , показывающее сколько раз встречается вариант x_i в вариационном ряду, называется **частотой значения** x_i , а $w_i = \frac{m_i}{n}$ – **относительной частотой** или **частотью**.

Вариационный ряд в случае дискретного признака X можно записать в виде таблицы, в которой будут перечислены все различные значения x_i и соответствующие им частоты (или относительные частоты):

x_i	x_1	x_2	...	x_k
m_i	m_1	m_2	...	m_k

Такая таблица называется **сгруппированным вариационным рядом** или **статистическим распределением выборки**.

Пример 1. На некоторой мини АТС (автоматическая телефонная станция) на протяжении 20 минут проводились наблюдения над количеством соединений в минуту. В результате были получены значения числа соединений для каждой минуты: 2,3,2,1,4,2,0,1,2,3,3,1,2,5,2,1,0,4,1,1. Построить вариационный ряд в сгруппированном и несгруппированном виде.

Решение: Располагая значения в порядке неубывания получим вариационный ряд: 0,0,1,1,1,1,1,1,2,2,2,2,2,3,3,3,4,4,5. В данном случае исследуемый признак X – число соединений в минуту, является дискретной случайной величиной, возможные значения которой 0, 1, 2, 3, Запишем этот вариационный ряд в сгруппированном виде:

x_i	0	1	2	3	4	5
m_i	2	6	6	3	2	1

В случае непрерывного распределения признака X в выборке значений $x_1, x_2, \dots, x_n$ практически все значения будут различными. При больших объемах выборки изучение такого массива данных не очень удобно. С целью получения более компактной формы представления данных проводят их группировку. Для этого находят $x_{\min} = \min\{x_i\}$ и $x_{\max} = \max\{x_i\}$. Отрезок $[x_{\min}; x_{\max}]$ называют интервалом варьирования. Его разбивают на несколько интервалов, как правило, равной длины. Рекомендуемое количество интервалов k находят по формуле Стерджеса: $k=1+3,322 \lg n$. В случае нецелого значения k округляют до ближайшего большего целого значения.

Длина одного интервала будет определяться формулой: $h = \frac{x_{\max} - x_{\min}}{k}$

Таким образом, весь интервал варьирования будет разбит на интервалы:

$[a_1; a_2), [a_2; a_3), \dots, [a_k; a_{k+1}]$, где $a_1 = x_{\min}$, $a_2 = a_1 + h$, $a_3 = a_2 + h$, $a_{k+1} = a_k + h$.

Число вариантов, принадлежащих интервалу $[a_i; a_{i+1})$, называют частотой, соответствующей этому интервалу, и обозначают m_i .

Таблица, в которой указаны полученные в результате интервалы и соответствующие им частоты, называется **интервальным вариационным рядом**:

интервал	$[a_1; a_2)$	$[a_2; a_3)$	...	$[a_k; a_{k+1}]$
частота	m_1	m_2	...	m_k

Вместо частот иногда указывают относительные частоты $w_i = \frac{m_i}{n}$.

Пример 2. Изготовлена партия электролампочек определенного типа в количестве 5000 штук. Для проверки соответствия ТУ из партии случайным образом отобрано 50 лампочек и измерено значение их срока службы. Получены следующие данные:

885, 943, 1018, 1002, 934, 1010, 976, 991, 988, 911, 860, 1007, 941, 1016, 1027, 1062, 1023, 983, 1073, 1051, 988, 1027, 974, 996, 1069, 932, 965, 1026, 1018, 1014, 907, 1051, 1004, 1074, 1025, 1007, 955, 1044, 1140, 1091, 916, 952, 1064, 1011, 947, 985, 1085, 942, 1038, 938.

Построить интервальный вариационный ряд для этой выборки.

Решение: Количество интервалов разбиения $k=1+3,322\lg 50 \approx 6,9$, значит $k=7$.

Найдем наибольшее и наименьшее значения в выборке: $x_{\min} = 860$, $x_{\max} = 1140$.

Длина интервала разбиения будет равна: $h = \frac{1140-860}{7} = 40$

Запишем полученные интервалы разбиения и найдем частоты, подсчитывая количество вариантов, попавших в каждый интервал.

интервал	[860;900)	[900;940)	[940;980)	[980;1020)	[1020;1060)	[1060;1100)	[1100; 1140]
частота	2	6	9	15	1 0	7	1

Для графического изображения вариационных рядов используются полигон или гистограмма частот.

Полигоном частот называется ломаная линия, получаемая путем последовательного соединения точек с координатами $(x_i; m_i)$, $i=1, 2, \dots, k$, отрезками (для относительных частот $(x_i; w_i)$, $i=1, 2, \dots, k$). Полигон используется для изображения дискретных вариационных рядов.

Для изображения интервальных вариационных рядов используют **гистограмму** – ступенчатую диаграмму, для которой на каждом интервале разбиения значение функции равно соответствующей ему частоте.

Полигон и гистограмма относительных частот являются статистическими аналогами закона распределения и плотности вероятности соответственно исследуемого признака X .

3. ЧИСЛОВЫЕ ХАРАКТЕРИСТИКИ ВАРИАЦИОННЫХ РЯДОВ. СРЕДНИЕ ВЕЛИЧИНЫ

Средние величины характеризуют значения признака, около которого располагаются наблюдения. Самой распространенной из них является выборочная средняя.

Выборочной средней или **средней арифметической** несгруппированного вариационного ряда называется сумма всех его вариантов, деленная на их количество (объем выборки): $\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}$.

Для сгруппированного ряда выборочная средняя вычисляется по формуле $\bar{x} = \frac{\sum_{i=1}^k x_i m_i}{n}$, где m_i – частота, соответствующая значениям x_i , $n = \sum_{i=1}^k m_i$ – объем выборки.

В случае интервального вариационного ряда в качестве x_i берут середины интервалов.

Пример 3. Найдите выборочную среднюю вариационных рядов, указанную в примерах 1 и 2.

$$\text{Решение для примера 1: } \bar{x} = \frac{0 \cdot 2 + 1 \cdot 6 + 2 \cdot 6 + 3 \cdot 3 + 4 \cdot 2 + 5 \cdot 1}{20} = 2;$$

$$\text{Для примера 2: } \bar{x} = \frac{880 \cdot 2 + 920 \cdot 6 + 960 \cdot 9 + 1000 \cdot 15 + 1040 \cdot 10 + 1080 \cdot 7 + 1120 \cdot 1}{50} = 1000.$$

Модой *Мо вариационного ряда* называется вариант, которому соответствует наибольшая частота. Может оказаться так, что наибольшая частота соответствует сразу нескольким вариантам. Тогда модами будут все такие варианты, а вариационный ряд в таком случае называют **полимодальным**. Для интервальных вариационных рядов мода вычисляется по формуле: $M_0 = x_0 + h \cdot \frac{m_0 - m_1}{2m_0 - m_1 - m_2}$, где x_0 – левая граница модального интервала (интервала, имеющего наибольшую частоту m_0), m_1, m_2 – частоты, соответствующие интервалам, предшествующему модальному и следующему за ним соответственно, h – длина интервалов.

Медианой *Ме* вариационного ряда называется вариант, располагающийся в середине ряда в случае, если этот ряд содержит нечетное число значений, и среднее арифметическое двух вариантов $\frac{x_k + x_{k+1}}{2}$, расположенных в середине ряда в случае, когда число всех значений четно. Для интервальных вариационных рядов медиана вычисляется по формуле: $M_e = x_e + h \cdot \frac{\frac{n}{2} - S_e}{m_e}$, где x_e – левая граница интервала, в который попадает вариант с номером $\frac{n}{2}$ (или $\frac{n+1}{2}$), m_e – частота, соответствующая этому интервалу, S_e – сумма всех частот, предшествующих этому интервалу.

Пример 4. Найдите моду и медиану для вариационных рядов, указанных в примерах 1 и 2.

Решение: Для примера 1 наибольшая частота равна 6 и она соответствует значениям 1 и 2. Следовательно, это бимодальный вариационный ряд и его мода равна 1 и 2. Медиана $M_e = \frac{2+2}{2} = 2$, т.к. в середине вариационного ряда располагаются $x_{10} = 2$, $x_{11} = 2$.

Для примера 2 модальным интервалом будет интервал $[980; 1020]$, так как соответствующая ему частота наибольшая и равна 15. Значит $x_0 = 980, m_0 = 15, m_1 = 9, m_2 = 10, h = 40$.

$$M_0 = 980 + 40 \cdot \frac{15-9}{2 \cdot 15 - 9 - 10} = 980 + \frac{240}{11} \approx 1001,8$$

Чтобы найти медиану, определим интервал, в который попадает вариант с номером 25. Суммируя частоты получим, что в интервале $[980; 1020]$ располагаются варианты с номерами от 19 до 32. Следовательно, $x_e = 980, m_e = 15, S_e = 2 + 6 + 9 = 17$. Значит, медиана будет равна $M_e = 980 + 40 \cdot \frac{25-17}{15} \approx 1001,3$.

ПОКАЗАТЕЛИ ВАРИАЦИИ

Простейшим из показателей вариации является **вариационный размах** R , величина, равная разности между наибольшим и наименьшим вариантами вариационного ряда.
 $R = x_{\max} - x_{\min}$

Наиболее важными из показателей вариации являются числовые характеристики вариационных рядов, характеризующие степень рассеяния наблюдений относительно средней арифметической.

Средним линейным отклонением d вариационного ряда называется средняя арифметическая модулей отклонений вариантов от их средней арифметической. $d = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}$ для несгруппированного вариационного ряда или $d = \frac{\sum_{i=1}^n |x_i - \bar{x}| \cdot m_i}{n}$ для сгруппированного вариационного ряда.

Выборочной дисперсией S^2 вариационного ряда называется средняя арифметическая квадратов отклонений вариантов от средней арифметической: $S^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$ для несгруппированного вариационного ряда или $S^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot m_i}{n} = \sum_{i=1}^n (x_i - \bar{x})^2 w_i$ для сгруппированного вариационного ряда.

Выборочным среднеквадратическим отклонением вариационного ряда называется корень квадратный из выборочной дисперсии $S = \sqrt{S^2}$.

Коэффициентом вариации v признака называется процентное отношение выборочного среднеквадратического отношения к модулю средней арифметической: $v = \frac{S}{|\bar{x}|} \cdot 100\%$.

Коэффициент вариации является безразмерной характеристикой и позволяет оценить степень однородности выборки. В статистике принято считать, что если значение коэффициента вариации ниже 33%, то выборка считается однородной, если больше 33%, то неоднородной.

Пример 5: Найдите среднее линейное отклонение, выборочную дисперсию, выборочное среднеквадратичное отклонение и коэффициент вариации для примеров 1 и 2.

Решение: Для примера 1 $\bar{x} = \frac{0 \cdot 1 + 1 \cdot 6 + 2 \cdot 6 + 3 \cdot 3 + 4 \cdot 2 + 5 \cdot 1}{20} = 2$.

Тогда $d = \frac{|0-2| \cdot 2 + |1-2| \cdot 6 + |2-2| \cdot 6 + |3-2| \cdot 3 + |4-2| \cdot 2 + |5-2| \cdot 1}{20} = 1$.

$S^2 = \frac{(0-2)^2 \cdot 2 + (1-2)^2 \cdot 6 + (2-2)^2 \cdot 6 + (3-2)^2 \cdot 3 + (4-2)^2 \cdot 2 + (5-2)^2 \cdot 1}{20} = 1,7$. $S = \sqrt{1,7} \approx 1,30$, $v = \frac{1,30}{2} \cdot 100\% = 65\%$.

Для примера 2 $\bar{x} = \frac{880 \cdot 2 + 920 \cdot 6 + 960 \cdot 9 + 1000 \cdot 15 + 1040 \cdot 10 + 1080 \cdot 7 + 1120 \cdot 1}{50} = 1000$.

$d = \frac{|880-1000| \cdot 2 + |920-1000| \cdot 6 + |960-1000| \cdot 9 + |1000-1000| \cdot 15 + |1040-1000| \cdot 10 + |1080-1000| \cdot 7 + |1120-1000| \cdot 1}{50} = \frac{2160}{50} = 43,2$.

$S^2 = \frac{(880-1000)^2 \cdot 2 + (920-1000)^2 \cdot 6 + (960-1000)^2 \cdot 9 + (1000-1000)^2 \cdot 15 + (1040-1000)^2 \cdot 10 + (1080-1000)^2 \cdot 7 + (1120-1000)^2 \cdot 1}{50} = \frac{156800}{50} = 3136$. $S = \sqrt{3136} = 56$. $v = \frac{56}{1000} \cdot 100\% = 5,6\%$.

Лекция 2. СТАТИСТИЧЕСКОЕ ОЦЕНИВАНИЕ НЕИЗВЕСТНЫХ ПАРАМЕТРОВ

1. ТОЧЕЧНОЕ ОЦЕНИВАНИЕ ПАРАМЕТРОВ

Пусть проводится исследование некоторого признака X генеральной совокупности. Обозначим θ – некоторый неизвестный параметр случайной величины X . Так, например, если случайная величина X распределена по закону Пуассона, то неизвестным может быть параметр λ этого распределения. Задача исследователя заключается в том, чтобы

основываясь на полученных в результате эксперимента данных $x_1, x_2, \dots, x_n$ (выборки значений случайной величины X) получить приближенное значение этого параметра θ .

Определение. *Оценкой θ_n^* неизвестного параметра θ* называется функция $\theta^*(x_1, x_2, \dots, x_n)$, зависящая от выборочных данных, значение которой приближенно равно неизвестному параметру.

Значение θ^* для каждой конкретной выборки является числом. Поэтому такая оценки называется **точечной**. Каждое значение x_i можно рассматривать как значение случайной величины X_i , представляющей результат i -го наблюдения величины X . Если все наблюдения независимы, то величина X_i также независима и имеет такой же закон распределения, что и сама случайная величина X . Функция результатов наблюдений $\theta^*(x_1, x_2, \dots, x_n)$ называют **статистикой**.

В силу вышесказанного, статистика, определяющая оценку неизвестного параметра θ , является случайной величиной, зависящей от закона распределения случайной величины X и объема выборки n .

Для оценивания одного и того же параметра могут предлагаться различные статистики. Так, например, в качестве оценки математического ожидания случайной величины X можно взять арифметическую среднюю $\bar{x}$, или моду M_0 , или медиану M_e и т.д. (результаты примера 3 показывают, что различия между этими оценками незначительны)

Для того, чтобы оценка считалась качественной, она должна обладать свойствами **несмещенности, состоятельности и эффективности**.

Определение. Оценка $\theta^*(X_1, X_2, \dots, X_n)$ параметра θ называется **несмещенной**, если ее математическое ожидание равно оцениваемому параметру θ , т.е. если $M(\theta_n^*) = \theta$.

В противном случае оценка называется смещенной. Несмещенность оценки позволяет гарантировать отсутствие систематических ошибок при получении оценок, т.е. несмотря на то, что каждая конкретная оценка может отличаться от истинного значения параметра θ , средняя арифметическая большого количества полученных по различным выборкам оценок будет равна θ .

Определение. Оценка $\theta^*(X_1, X_2, \dots, X_n)$ параметра θ называется **состоятельной**, если она стремится к оцениваемому параметру θ по вероятности, т.е. если для любого $\varepsilon > 0$ $\lim_{n \rightarrow \infty} P(|\theta_n^* - \theta| < \varepsilon) = 1$

Таким образом, для состоятельной оценки практически достоверно, что при большом объеме выборки n $\theta_n^* \approx \theta$.

Теорема 1. Если оценка θ_n^* является несмещенной, а ее дисперсия $D(\theta_n^*) \rightarrow 0$ при $n \rightarrow \infty$, то оценка θ_n^* является и состоятельной.

Доказательство очевидным образом следует из неравенства Чебышева: $P(|\theta_n^* - \theta| < \varepsilon) \geq 1 - \frac{D(\theta_n^*)}{\varepsilon^2}$, где $1 - \frac{D(\theta_n^*)}{\varepsilon^2} \rightarrow 1$ при $n \rightarrow \infty$, т.к. $D(\theta_n^*) \rightarrow 0$.

Определение. Несмещенная оценка $\theta^*(X_1, X_2, \dots, X_n)$ параметра θ называется **эффективной**, если она имеет наименьшую дисперсию среди всех возможных несмещенных оценок параметра θ , полученных по выборкам одного и того же объема n .

В качестве статистических оценок параметров генеральной совокупности желательно использовать несмещенные, состоятельные и эффективные оценки. Однако на практике иногда рассматривают оценки асимптотически несмещенные, т.е. такие, для которых

$\lim_{n \rightarrow \infty} M(\theta_n^*) = \theta$, а также оценки, обладающие большей дисперсией по сравнению с эффективной оценкой этого параметра.

2. ВЫБОРОЧНАЯ СРЕДНЯЯ КАК НЕСМЕЩЕННАЯ И СОСТОЯТЕЛЬНАЯ ОЦЕНКА ГЕНЕРАЛЬНОЙ СРЕДНЕЙ

Теорема 2. Выборочная средняя $\bar{x}$ является несмещенной и состоятельной оценкой генеральной средней $M(X)$.

Доказательство: $\bar{x} = \frac{X_1 + X_2 + \dots + X_n}{n}$, где X_i – случайная величина, выражающая значение признака X для i -го элемента выборки. Если выборка повторная, то все X_i независимы и имеют распределение, совпадающее с распределением случайной величины X .

Пусть $M(X)=m$, $D(X)=\sigma^2$, (m – неизвестный параметр – генеральное среднее – подлежащий оценке)

Тогда все математические ожидания $M(X_i)=m$, а $D(X_i)=\sigma^2$.

$$M(\bar{x}) = M\left(\frac{X_1 + X_2 + \dots + X_n}{n}\right) = \frac{1}{n}(M(X_1) + M(X_2) + \dots + M(X_n)) = \frac{1}{n}(m + m + \dots + m) = \frac{n \cdot m}{n} = m.$$

Мы доказали, что оценка $\bar{x}$ является несмещенной, т.к. $M(\bar{x}) = m$. Найдём $D(\bar{x})$.

$$D(\bar{x}) = D\left(\frac{X_1 + X_2 + \dots + X_n}{n}\right) = \frac{1}{n^2}(D(X_1) + D(X_2) + \dots + D(X_n)) = \frac{1}{n^2}(\sigma^2 + \sigma^2 + \dots + \sigma^2) = \frac{n \cdot \sigma^2}{n^2} = \frac{\sigma^2}{n}. \quad D(\bar{x}) = \frac{\sigma^2}{n} \rightarrow 0 \text{ при } n \rightarrow \infty, \text{ следовательно, в силу теоремы 1, оценка } \bar{x} \text{ является состоятельной.}$$

Для бесповторной выборки можно доказать, что $M(\bar{x})=m$ (т.е. $\bar{x}$ – несмещенная оценка), а

$$D(\bar{x}) = \frac{\sigma^2}{n} \left(\frac{N-n}{N-1} \right) \approx \frac{\sigma^2}{n} \left(1 - \frac{n}{N} \right), \text{ где } N - \text{ объем генеральной совокупности. В этом случае } D(\bar{x}) \text{ также стремится к нулю, из чего следует состоятельность оценки.}$$

Можно доказать, что в случае нормального распределения признака X оценка $\bar{x}$ будет эффективной.

3. ВЫБОРОЧНАЯ ДИСПЕРСИЯ И ИСПРАВЛЕННАЯ ВЫБОРОЧНАЯ ДИСПЕРСИЯ КАК ОЦЕНКИ ГЕНЕРАЛЬНОЙ СОВОКУПНОСТИ $D(X)$

Теорема 3. Выборочная дисперсия S^2 является смещенной, состоятельной оценкой генеральной дисперсии $D(X)=\sigma^2$.

Доказательство: Можно показать, что если все значения признака X в выборке уменьшать на одно и то же число c , то $\overline{x-c} = \bar{x} - c$, а дисперсия не изменится, $S^2 = S_{x-c}^2 = \overline{(x-c)^2} - (\overline{x-c})^2$. Полагая, $c=m=M(X)$, получим $S^2 = \overline{(x-m)^2} - (\overline{x-m})^2 = \overline{(x-m)^2} - (\bar{x}-m)^2$.

$$\begin{aligned} \text{Для повторной выборки} \quad M(S^2) &= M\left(\frac{(X_1-m)^2 + (X_2-m)^2 + \dots + (X_n-m)^2}{n}\right) - \\ M(\bar{x}-m)^2 &= \frac{1}{n}(M(X_1-m)^2 + M(X_2-m)^2 + \dots + M(X_n-m)^2) - M((\bar{x})^2 - 2m\bar{x} + \\ m^2) &= \frac{1}{n}(D(X_1) + D(X_2) + \dots + D(X_n)) - M(\bar{x})^2 + 2m \cdot M(\bar{x}) - m^2 = \frac{n\sigma^2}{n} - (M(\bar{x})^2 - \\ m^2). \text{ Но } M(\bar{x})^2 - m^2 &= D(\bar{x}) = \frac{\sigma^2}{n}, \text{ т.к. } M(\bar{x})=m, \text{ следовательно, } M(S^2) = \frac{n\sigma^2}{n} - \frac{\sigma^2}{n} = \sigma^2 - \\ \frac{\sigma^2}{n} &= \frac{n-1}{n}\sigma^2. \text{ Оценка смещена влево, т.к. } M(S^2) < \sigma^2. \text{ Но при } n \rightarrow \infty, M(S^2) \rightarrow \sigma^2, \text{ т.е.} \end{aligned}$$

она является асимптотически несмещенной. Чтобы получить несмещенную оценку генеральной дисперсии можно скорректировать выборочную дисперсию S^2 , рассмотрев исправленную выборочную дисперсию $S_i^2 = \frac{n}{n-1} \cdot S^2$.

$M(S_i^2) = M\left(\frac{n}{n-1} \cdot S^2\right) = \frac{n}{n-1} M(S^2) = \frac{n}{n-1} \cdot \frac{n-1}{n} \cdot \sigma^2$, что доказывает ее несмещенность. Состоятельность оценки S_i^2 вытекает из состоятельности оценки S^2

Пример 6. Найдите несмещенные и состоятельные оценки среднего срока службы лампочек и его дисперсии (пример 2).

Решение. Несмещенной и состоятельной оценкой генеральной средней (срока службы) является выборочная средняя $\bar{x} = 1000$. Несмещенной и состоятельной оценкой дисперсии будет исправленная выборочная дисперсия $S_i^2 = \frac{n}{n-1} \cdot S^2 = \frac{50}{49} \cdot 3136 = 3200$

4. СОСТОЯТЕЛЬНАЯ И НЕСМЕЩЕННАЯ ОЦЕНКА ГЕНЕРАЛЬНОЙ ДОЛИ

Пусть генеральная совокупность содержит N элементов, из которых M элементов обладает некоторым признаком A . Генеральной долей объектов этой совокупности, обладающих признаком A , называется величина $p = \frac{M}{N}$. Рассмотрим в качестве оценки параметра p его статистический аналог – выборочную долю $w = \frac{m}{n}$, где n – объем выборки, m – число элементов выборки, обладающих признаком A . Вычислим математическое ожидание и дисперсию оценки w . Для этого рассмотрим случайные величины $X_1, X_2, \dots, X_n$, где $X_i = 1$, если i -ый элемент выборки обладает признаком A , и $X_i = 0$ в противном случае.

Для повторной выборки случайные величины X_i независимы и одинаково распределены, т.к. $P(X_i = 1) = \frac{M}{N} = p$, $P(X_i = 0) = \frac{N-M}{N} = 1 - p = q$.

Значит, $M(X_i) = 0 \cdot q + 1 \cdot p = p$. $D(X_i) = M(X_i^2) - M^2(X_i) = (0 \cdot q + 1 \cdot p) - p^2 = pq$.

Так как $m = \sum_{i=1}^n X_i$, то оценку w можно представить в виде $w = \frac{\sum X_i}{n}$.

Тогда $M(w) = \frac{1}{n} \sum_{i=1}^n (M(X_i)) = \frac{np}{n} = p$. $D(w) = \frac{1}{n^2} \sum_{i=1}^n (D(X_i)) = \frac{npq}{n^2} = \frac{pq}{n}$.

Теорема 4. Выборочная доля w является несмещенной и состоятельной оценкой генеральной доли p .

Доказательство: Мы показали, что $M(w) = p$, следовательно, оценка несмещенная.

Так как $D(w) = \frac{pq}{n} \rightarrow 0$ при $n \rightarrow \infty$, то в силу теоремы 1 оценка является состоятельной.

В случае бесповторной выборки случайные величины X_i являются зависимыми, но можно показать, что закон распределения каждой из них не изменится, т.е. $P(X_i = 1) = p$, $P(X_i = 0) = q$. Следовательно, $M(X_i) = p$ и $M(w) = p$, что доказывает несмещенность оценки.

В этом случае $D(w) = \frac{pq}{n} \cdot \frac{N-n}{N-1} \approx \frac{pq}{n} (1 - \frac{n}{N})$. Дисперсия стремится к нулю при $n \rightarrow \infty$, следовательно, оценка w является состоятельной в силу теоремы 1.

Пример 7. Найдите несмещенную и состоятельную оценку доли лампочек, срок службы которых не превышает 940 часов.

Решение. Число лампочек в выборке со сроком службы не превышающим 940 часов равно $2+6=8$. Следовательно, доля таких лампочек в выборке равна $w = \frac{8}{50} = 0,16$ и является несмещенной и состоятельной оценкой аналогичной доли во всей партии.

5. ИНТЕРВАЛЬНОЕ ОЦЕНИВАНИЕ ПАРАМЕТРОВ

Для того, чтобы иметь представление о точности и надежности оценки неизвестного параметра θ используют его интервальную оценку. Задача интервального оценивания может быть сформулирована следующим образом: по имеющимся выборочным данным получить интервал (θ_1^*, θ_2^*) , внутри которого с заранее заданной вероятностью γ будет находиться значение неизвестного параметра θ . В этом случае говорят, что интервал (θ_1^*, θ_2^*) накрывает с вероятностью γ истинное значения параметра θ . Интервал (θ_1^*, θ_2^*) называется **доверительным интервалом**, его границы θ_1^* и θ_2^* – **доверительными границами**, а γ – **доверительной вероятностью** или **надежностью оценки**.

Обычно в качестве значения γ выбирают число близкое к 1: 0,9, 0,95, 0,99. Надежность, как правило, выражают в процентах. Например, надежность 95% соответствует $\gamma = 0,95$. Часто доверительный интервал выбирается симметричным относительно несмещенной оценки θ^* параметра θ , то есть в виде $(\theta^* - \Delta, \theta^* + \Delta)$. Число Δ называют предельной ошибкой выборки. Оно характеризует точность оценки.

ДОВЕРИТЕЛЬНЫЙ ИНТЕРВАЛ ДЛЯ ГЕНЕРАЛЬНОГО СРЕДНЕГО

Пусть X – исследуемый признак, $M(X)=m$ – его математическое ожидание или генеральное среднее. Выборочная средняя $\bar{x} = \frac{X_1+X_2+\dots+X_n}{n}$ при больших объемах выборок в силу теоремы Ляпунова может считаться нормально распределенной случайной величиной с параметрами $M(\bar{x})=m$, $D(\bar{x}) = \frac{\sigma^2}{n}$ (для повторной выборки) и $D(\bar{x}) = \frac{\sigma^2}{n} (1 - \frac{n}{N})$ (для бесповторной выборки).

Тогда $P(|\bar{x} - m| < \Delta) = \Phi\left(\frac{\Delta}{\sigma_{\bar{x}}}\right) = \gamma$. Из этого равенства следует, что $m \in (\bar{x} - \Delta; \bar{x} + \Delta)$ с заданной вероятностью γ . Предельную ошибку выборки Δ найдем из равенства $\Phi\left(\frac{\Delta}{\sigma_{\bar{x}}}\right) = \gamma$. Следовательно, $\frac{\Delta}{\sigma_{\bar{x}}} = t_\gamma$, где $\Phi(t_\gamma) = \gamma$ и $\Delta = t_\gamma \cdot \sigma_{\bar{x}}$. Окончательно получим формулу доверительного интервала для генерального среднего: $\bar{x} - \Delta < m < \bar{x} + \Delta$, где $\Delta = t_\gamma \cdot \sigma_{\bar{x}}$, $\Phi(t_\gamma) = \gamma$, $\sigma_{\bar{x}} = \sqrt{D(\bar{x})}$

На практике, как правило, генеральная дисперсия σ^2 неизвестна, поэтому ее заменяют на исправленную выборочную дисперсию S_i^2 .

Следует отметить, что для выборки малого объема заключение о нормальном распределении $\bar{x}$ становится необоснованным, а значит и формула доверительного интервала должна пересматриваться.

Пример 8. Получите 95% доверительный интервал для среднего срока службы лампочки (пример 2)

Решение. Если m – средний срок службы лампочки, то доверительный интервал будет определяться формулой $\bar{x} - \Delta < m < \bar{x} + \Delta$, $\bar{x} = 1000$ час., $\Delta = t_{0,95} \cdot \sigma_{\bar{x}}$, $t_{0,95} = 1,96$, т. к. $\Phi(1,96) = 0,95$ $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{50}} \sqrt{1 - \frac{50}{5000}}$. Поскольку σ неизвестно, заменим его оценкой – исправленным среднеквадратическим отклонением $S_i = 56,57$ $\sigma_{\bar{x}} = \frac{56,57}{\sqrt{50}} \sqrt{0,99} \approx 7,96$, $\Delta = 1,96 \cdot 7,96 = 15,60$.

Окончательно $1000-15,60 < m < 1000+15,60$ или $984,4 < m < 1015,6$.

ДОВЕРИТЕЛЬНЫЙ ИНТЕРВАЛ ДЛЯ ГЕНЕРАЛЬНОЙ ДОЛИ

Выборочная доля $w = \frac{m}{n} = \frac{X_1 + X_2 + \dots + X_n}{n}$ является несмещенной оценкой генеральной доли p и при больших n статистика w в силу теоремы Ляпунова имеет нормальное распределение с параметрами $M(w)=p$, $D(w)=\frac{pq}{n}$ (для повторной выборки) и $D(w) = \frac{pq}{n} (1 - \frac{n}{N})$ (для бесповторной выборки). Тогда $P(|w - p| < \Delta) = \Phi\left(\frac{\Delta}{\sigma_w}\right) = \gamma$, из чего следует, что $p \in (w - \Delta; w + \Delta)$ с вероятностью γ и предельная ошибка выборки Δ находится из равенства $\frac{\Delta}{\sigma_w} = t_\gamma$, где $\Phi(t_\gamma) = \gamma$. Окончательно формула доверительного интервала для генеральной доли имеет вид $w - \Delta < m < w + \Delta$, где $\Delta = t_\gamma \cdot \sigma_w$

Пример 9. Получить 95% доверительный интервал для доли лампочек, имеющих срок службы менее 940 часов. (пример 2)

Решение. Выборочная доля лампочек со сроком службы менее 940 часов равна $w = \frac{2+6}{50} = \frac{8}{50} = 0,16$, $t_{0,95} = 1,96$, $\sigma_w^2 = \frac{pq}{n} \left(1 - \frac{n}{N}\right) = \frac{0,16 \cdot 0,84}{50} \left(1 - \frac{50}{5000}\right) = 0,00266$ $\sigma_w \approx 0,05$ (поскольку значение p неизвестно, в качестве его оценки использовали выборочную долю w). $\Delta = t_\gamma \cdot \sigma_w = 1,96 \cdot 0,05 = 0,1$

Окончательно $0,16 - 0,1 < p < 0,16 + 0,1$ или $0,06 < p < 0,26$, т.е. с вероятностью 0,95 можем утверждать, что доля таких лампочек будет находиться в пределах 6% - 26%.